

数值代数期末重点

期末：不考程序，全是理论上的。五道题（证明和计算）

复习：基本定义和作业

必考：3.1.4

可能会默写的定理：

1. QR分解
2. jordan分解
3. schur分解
4. gerschgorin圆盘
5. 实schur分解
6. 谱分解
7. 极小极大值原理
8. weyl
9. svd分解

第二章

定义 2.1.1 (向量范数, p41)

从 $\mathbb{R}^n$ 到 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 被称作 $\mathbb{R}^n$ 上的向量范数，如果它满足

- (1) 正定性: $\forall x \in \mathbb{R}^n, \|x\| \geq 0; \|x\| = 0 \iff x = 0$ 。
- (2) 齐次性: $\forall x \in \mathbb{R}^n, \alpha \in \mathbb{R}, \|\alpha x\| = |\alpha| \|x\|$ 。
- (3) 三角不等式: $\forall x, y \in \mathbb{R}^n, \|x + y\| \leq \|x\| + \|y\|$ 。

定义 2.1.2 (矩阵范数, p43)

从 $\mathbb{R}^{n \times n}$ 到 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 被称作 $\mathbb{R}^{n \times n}$ 上的向量范数，如果它满足

- (1) 正定性: $\forall A \in \mathbb{R}^{n \times n}, \|A\| \geq 0; \|A\| = 0 \iff A = 0$ 。
- (2) 齐次性: $\forall A \in \mathbb{R}^{n \times n}, \alpha \in \mathbb{R}, \|\alpha A\| = |\alpha| \|A\|$ 。
- (3) 三角不等式: $\forall A, B \in \mathbb{R}^{n \times n}, \|A + B\| \leq \|A\| + \|B\|$ 。
- (4) 相容性: $\forall A, B \in \mathbb{R}^{n \times n}, \|AB\| \leq \|A\| \|B\|$ 。

定义 2.1.4 (A 的谱半径, $\rho(A)$, p48)

$$\rho(A) = \max\{|\lambda| : \lambda \in \lambda(A)\}, \quad (1)$$

这里 $\lambda(A)$ 代表 A 的特征值的全体。

定义列和范数 (Column Sum Norm): $\|A\|_1$

它是矩阵每一列元素绝对值之和的最大值。

计算公式:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \quad (2)$$

- **口诀:** 先求每列绝对值之和, 再取最大。

定义行和范数 (Row Sum Norm): $\|A\|_\infty$

它是矩阵每一行元素绝对值之和的最大值。

计算公式:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \quad (3)$$

- **口诀:** 先求每行绝对值之和, 再取最大。

定义谱范数 (Spectral Norm): $\|A\|_2$

它是矩阵 $A^H A$ (A 的共轭转置乘以 A) 的最大特征值的平方根。

计算公式:

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^H A)} = \sqrt{\rho(A^H A)} \quad (4)$$

其中:

- $\lambda_{\max}(M)$ 表示矩阵 M 的最大特征值, 也就是谱半径。
- $\sigma_{\max}(A)$ 表示矩阵 A 的最大奇异值。

定理 2.1.6 (谱半径与矩阵范数关系, p49)

对于任何相容的矩阵范数 $\|\cdot\|$, 矩阵 A 的谱半径总是小于或等于该范数:

$$\rho(A) \leq \|A\| \quad (5)$$

定理2.1.7 (A^k 收敛的充分必要条件, p50)

$$\lim_{k \rightarrow \infty} A^k = 0 \iff \rho(A) < 1. \tag{6}$$

定理 2.1.8 (A 的 *Neumann series*, p51)

(1) $\sum_{k=0}^{\infty} A^k$ 收敛 $\iff \rho(A) < 1$.

(2) 当 $\sum_{k=0}^{\infty} A^k$ 收敛时, 有

$$\sum_{k=0}^{\infty} A^k = (I - A)^{-1}. \tag{7}$$

且存在范数 $\|\cdot\|$ 使得对于任意自然数 m , 有

$$\|(I - A)^{-1} - \sum_{k=0}^m A^k\| \leq \frac{\|A\|^{m+1}}{1 - \|A\|}. \tag{8}$$

敏度分析

这tm能考。

补一个定义:

称数

$$\kappa(A) = \|A\| \|A^{-1}\| \tag{9}$$

为线性方程组 $Ax = b$ 的条件数。

第三章

定义 3.1.1 (最小二乘问题, *LS*问题, p77)

给定 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, 确定 $x \in \mathbb{R}^n$ 使得

$$\|b - Ax\|_2 = \|r(x)\|_2 = \min_{y \in \mathbb{R}^n} \|r(y)\|_2 = \min_{y \in \mathbb{R}^n} \|Ay - b\|_2. \tag{10}$$

r 被称为残向量。本章中, 限定 $rank(A) = n < m$ 。

基本定义

$A \in \mathbb{R}^{m \times n}$, A 的值域为 $\mathcal{R}(A) = \{y \in \mathbb{R}^m : y = Ax, x \in \mathbb{R}^n\}$ 。

A 的零空间定义为 $\mathcal{N}(A) = \{x \in \mathbb{R}^n : Ax = 0\}$, 其维数为 $null(A)$ 。

$\mathcal{S} \subset \mathbb{R}^n$ 的正交补为 $\mathcal{S}^\perp = \{y \in \mathbb{R}^n : y^T x = 0, \forall x \in \mathcal{S}\}$ 。

$\mathcal{X}_{LS} = \{x \in \mathbb{R}^n : x \text{ 是最小二乘问题的解}\}$ 。 $\mathcal{X}_{LS}$ 中2范数最小的解写为 x_{LS} , 并称之为最小2范数解。

定理3.1.4

设 $A \in \mathbb{R}^{m \times n}$ 且 $\vec{b} \in \mathbb{R}^m$ 。对于向量 $\vec{x} \in \mathbb{R}^n$ ，以下两个陈述是等价的：

1. $\vec{x}$ 是线性方程组 $A\vec{x} = \vec{b}$ 的**最小二乘解**。即 $\vec{x}$ 满足： $\|\vec{b} - A\vec{x}\|_2 = \min_{\vec{y} \in \mathbb{R}^n} \|\vec{b} - A\vec{y}\|_2$
2. $\vec{x}$ 是**正规方程 (Normal Equations)** 的解： $A^T A\vec{x} = A^T \vec{b}$

证明：

若 x 为最小二乘解，则 $x = \min_{y \in \mathbb{R}^n} \|Ay - b\|_2^2$ 。

对于 $\forall y \in \mathbb{R}^n$ ，我们可以定义 $f(a) = \|A(x + ay) - b\|_2^2$ ，则有 $f(a)$ 在 0 点取到最小值。

若 $f(a)$ 在 $a = 0$ 处可导，其必为零。我们计算 $\epsilon^{-1}[f(\epsilon) - f(0)]$ 如下

$$\begin{aligned}\epsilon^{-1}[f(\epsilon) - f(0)] &= \epsilon^{-1} (\|A(x + \epsilon y) - b\|_2^2 - \|Ax - b\|_2^2) \\ &= \epsilon^{-1} (\|A(x + \epsilon y)\|_2^2 + \|b\|_2^2 - 2\langle A(x + \epsilon y), b \rangle - \|Ax\|_2^2 - \|b\|_2^2 + 2\langle Ax, b \rangle) \\ &= \epsilon^{-1} (\|Ax\|_2^2 + \epsilon^2 \|Ay\|_2^2 + 2\epsilon \langle Ax, Ay \rangle - 2\epsilon \langle Ay, b \rangle - \|Ax\|_2^2) \\ &= \epsilon \|Ay\|_2^2 + 2\langle Ax - b, Ay \rangle\end{aligned}\tag{11}$$

令 $\epsilon \rightarrow 0$ ，可以发现极限存在且为 $2\langle Ax - b, Ay \rangle$ 。因此我们有

$$f'(0) = \lim_{\epsilon \rightarrow 0} \epsilon^{-1}[f(\epsilon) - f(0)] = 2\langle Ax - b, Ay \rangle = 0.\tag{12}$$

我们已经证明对于任意 $y \in \mathbb{R}^n$ ， $\langle A^T(Ax - b), y \rangle = 0$ 。这意味着 $A^T Ax = A^T b$ 。

若正则化方程成立，即 x 满足 $A^T Ax = A^T b$ ，对于 $\forall y \in \mathbb{R}^n$ ，我们有

$$\begin{aligned}\|A(x + y) - b\|_2^2 &= \|Ay\|_2^2 - 2\langle Ax - b, Ay \rangle + \|Ax - b\|_2^2 \\ &= \|Ay\|_2^2 - 2\langle A^T(Ax - b), y \rangle + \|Ax - b\|_2^2 \\ &= \|Ay\|_2^2 + \|Ax - b\|_2^2 \\ &\geq \|Ax - b\|_2^2.\end{aligned}\tag{13}$$

由 y 的任意性，我们有 x 为 $Ax = b$ 的最小二乘解。

若 A 列线性无关，则最小二乘解可写为 $x = (A^T A)^{-1} A^T b$ 。定义 $A^\dagger = (A^T A)^{-1} A^T$ ，其为 *Moore-Penrose* 广义逆 (p82)。

最小二乘法的条件数定义为 $\kappa_2(A) = \|A\|_2 \|A^\dagger\|_2$ 。

定义 3.2.1 (p84)：

对于 $w \in \mathbb{R}^n$ 且满足 $\|w\|_2 = 1$ ，定义 *Householder* 变换 $H \in \mathbb{R}^{n \times n}$ 如下：

$$H = I - 2ww^T.\tag{14}$$

定理 3.2.2

设 $0 \neq x \in \mathbb{R}^n$ ，则可构造单位向量 $w \in \mathbb{R}^n$ ，使得由 (3.2.1) 式定义的 *Householder* 变换 H 满足

$$Hx = \alpha e_1,\tag{15}$$

其中 $\alpha = \pm \|x\|_2$ ， e_1 是 $e_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$ 。

定理 3.3.1 (QR 分解, p91) :

设 $A \in \mathbb{R}^{m \times n} (m \geq n)$, 则 A 的 QR 分解如下

$$A = Q \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad (16)$$

其中 $Q \in \mathbb{R}^{m \times m}$ 是正交矩阵, $R \in \mathbb{R}^{n \times n}$ 是具有非负对角元的上三角阵; 而且当 $m = n$ 且 A 非奇异时, 上述分解唯一。

第四章

雅可比迭代法 (Jacobi Method)

在数值线性代数中, **雅可比迭代法 (Jacobi Method)** 和 **高斯-赛德尔迭代法 (Gauss-Seidel Method)** 是求解线性方程组 $Ax = b$ 的两种最基本的迭代算法。

假设矩阵 A 被分解为: $A = D + L + U$ 其中:

- D : 对角矩阵 (Diagonal)
- L : 严格下三角矩阵 (Strict Lower Triangular)
- U : 严格上三角矩阵 (Strict Upper Triangular)

核心思想: 在计算第 $k+1$ 轮迭代值时, 全部使用第 k 轮的旧值。

矩阵形式公式:

$$x^{(k+1)} = D^{-1}(b - (L + U)x^{(k)}) \quad (17)$$

分量形式公式:

对于向量中的每一个元素 x_i , 其计算公式为:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right) \quad (18)$$

高斯-赛德尔迭代法 (Gauss-Seidel Method)

核心思想: 在计算第 $k+1$ 轮迭代值时, **立即使用**当前轮次已经计算出来的最新分量。这通常比雅可比法收敛更快。

矩阵形式公式:

$$x^{(k+1)} = (D + L)^{-1}(b - Ux^{(k)}) \quad (19)$$

分量形式公式:

注意求和符号中, 前一部分使用最新的 $k+1$ 轮值, 后一部分使用旧的 k 轮值:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right) \quad (20)$$

定理 4.2.1：线性定常迭代法收敛的充要条件

考虑求解线性方程组 $Ax = b$ 的单步线性定常迭代格式：

$$x^{(k+1)} = Mx^{(k)} + g, \quad k = 0, 1, 2, \dots \tag{21}$$

其中 M 为迭代矩阵， g 为常数向量。该迭代法对于任意初始向量 $x^{(0)}$ 均收敛于方程组的精确解 x^* 的充分必要条件是：迭代矩阵 M 的谱半径 $\rho(M)$ 小于 1，即：

$$\rho(M) = \max_{1 \leq i \leq n} |\lambda_i(M)| < 1 \tag{22}$$

定理 4.2.2

若迭代矩阵 M 的范数 $\|M\| = q < 1$ ，则上式迭代法所产生的近似解 x_k 与准确解 x_* 的误差有如下估计式：

$$\|x_k - x_*\| \leq \frac{q^k}{1 - q} \|x_1 - x_0\| \tag{23}$$

定理 4.2.3

若 $\|M\| = q < 1$ ，则迭代法 (4.1.8) 所产生的近似解 x_k 与准确解 x_* 的误差有如下的估计式：

$$\|x_k - x_*\| \leq \frac{q}{1 - q} \|x_{k-1} - x_k\| \tag{24}$$

定义 4.2.1

设矩阵 $A = [a_{ij}] \in \mathbf{R}^{n \times n}$ 。若对所有的 i ($1 \leq i \leq n$) 都有

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \tag{25}$$

并且 25 式中至少对一个 i 有严格不等号成立，则称 A 是弱严格对角占优的；如果 25 式对所有 i 都有严格不等号成立，则称 A 是严格对角占优的。

以行为单位!!!

定义 4.2.2

设矩阵 $A \in \mathbf{R}^{n \times n}$ 。如果存在 n 阶排列方阵 P ，使得

$$PAP^T = \begin{bmatrix} A_{11} & 0 \\ A_{12} & A_{22} \end{bmatrix}, \tag{26}$$

其中 A_{11} 是 r 阶方阵， A_{22} 是 $n - r$ 阶方阵，则称 A 是可约的（或可分的）；反之，如果不存在这样的排列矩阵，则称 A 是不可约的（或不可分的）。

排列方阵是一个方阵，其每一行和每一列都恰好有一个元素为 1，而其余元素均为 0。

定理 4.2.8

若矩阵 A 是严格对角占优的或不可约对角占优的，则 A 非奇异。

推论 4.2.1

若 A 是严格对角占优的或不可约对角占优的对称矩阵，则 A 正定。

定义

定义 $R_k(M) = \frac{-\ln \|M^k\|}{k}$ 为 k 次迭代的平均收敛速度；

定义 $R_\infty(M) = \lim_{k \rightarrow \infty} R_k(M)$ 为渐近收敛速度。

定理 4.3.1 (p117)：

渐近收敛速度公式， $R_\infty(M) = -\ln \rho(M)$ 。

第五章

这里是为了求解

$Ax = b$ (27)

定理5.1.1

设 $A \in \mathbb{R}^{n \times n}$ 是一个**对称正定矩阵** (Symmetric Positive Definite, SPD) , $b \in \mathbb{R}^n$ 是给定向量。则求解线性方程组：

$Ax = b$ (28)

等价于求二次泛函 $\varphi(x)$ 的全局极小值点，其中：

$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2}x^T Ax - b^T x$ (29)

即： $Ax^* = b$ 当且仅当 $\varphi(x^*) = \min_{x \in \mathbb{R}^n} \varphi(x)$ 。

最速下降法

最速下降法思路 and 实现： 确定方向 p_k , 确定距离 α_k 。

$p_k = r_k = b - Ax_k, \quad \alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}, \quad x_{k+1} = x_k + \alpha_k p_k.$ (30)

迭代的过程为

$x_k \implies (r_k, p_k, \alpha_k) \implies x_{k+1} \implies (r_{k+1}, p_{k+1}, \alpha_{k+1}) \implies \dots$ (31)

共轭梯度法

$r_{k+1} = r_k - \alpha_k A p_k, \alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}, \beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k},$ (32)

$x_{k+1} = x_k + \alpha_k p_k, p_{k+1} = r_{k+1} + \beta_k p_k.$ (33)

迭代的过程为：

$(x_k, r_k, p_k) \xrightarrow{\text{计算 } \alpha_k} \alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$ (34)

$\downarrow$ (35)

$$(\alpha_k, x_k, r_k, p_k) \xrightarrow{\text{更新解与残差}} \begin{cases} x_{k+1} = x_k + \alpha_k p_k \\ r_{k+1} = r_k - \alpha_k A p_k \end{cases} \quad (36)$$

$$\downarrow \quad (37)$$

$$(r_{k+1}, r_k) \xrightarrow{\text{计算 } \beta_k} \beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k} \quad (38)$$

$$\downarrow \quad (39)$$

$$(\beta_k, r_{k+1}, p_k) \xrightarrow{\text{更新方向}} p_{k+1} = r_{k+1} + \beta_k p_k \quad (40)$$

定理 5.2.1

由共轭梯度法得到的向量组 $\{r_i\}$ 和 $\{p_i\}$ 具有下面的性质：

- (1) $p_i^T r_j = 0, 0 \leq i < j \leq k$;
- (2) $r_i^T r_j = 0, i \neq j, 0 \leq i, j \leq k$;
- (3) $p_i^T A p_j = 0, i \neq j, 0 \leq i, j \leq k$;
- (4) $\text{span}\{r_0, \dots, r_k\} = \text{span}\{p_0, \dots, p_k\} = \mathcal{K}(A, r_0, k+1)$, 其中

$$\mathcal{K}(A, r_0, k+1) = \text{span}\{r_0, A r_0, \dots, A^k r_0\} \quad (41)$$

通常称之为 *Krylov* 子空间。

定理 5.2.2

用共轭梯度法计算得到的近似解 x_k 满足

$$\varphi(x_k) = \min\{\varphi(x) : x \in x_0 + \mathcal{K}(A, r_0, k)\} \quad (42)$$

或

$$\|x_k - x_*\|_A = \min\{\|x - x_*\|_A : x \in x_0 + \mathcal{K}(A, r_0, k)\}, \quad (43)$$

其中 $\|x\|_A = \sqrt{x^T A x}$, x_* 是方程组 $Ax = b$ 的解, $\mathcal{K}(A, r_0, k)$ 是由 (5.2.6) 式所定义的 *Krylov* 子空间。

第六章

基本概念

1. 核心定义：特征值与特征向量

对于一个 n 阶方阵 A , 如果存在非零向量 $\mathbf{v}$ 和标量 λ , 使得: $A\mathbf{v} = \lambda\mathbf{v}$

- **特征值** (λ): 反映了矩阵在特定方向上拉伸或压缩的比例。
- **特征向量** ($\mathbf{v}$): 在矩阵变换下方向保持不变 (仅长度改变) 的非零向量。

2. 特征多项式 (Characteristic Polynomial)

特征值是以下代数方程的根: $p(\lambda) = \det(\lambda I - A) = 0$ 这个关于 λ 的 n 次多项式称为**特征多项式**。

3. 谱集 (Spectrum)

矩阵 A 的所有特征值的集合称为该矩阵的**谱**, 通常记作 $\sigma(A)$ 。在物理和工程中, 谱集决定了系统的稳定性或共振频率。

4. 重数 (Multiplicity)

特征值的“重复次数”分为两种：

- **代数重数 (Algebraic Multiplicity)**：特征值作为特征多项式根的重数（即在方程中出现的次数）。
- **几何重数 (Geometric Multiplicity)**：对应于该特征值的线性无关特征向量的最大个数（即特征子空间 $\ker(\lambda I - A)$ 的维数）。

注意：几何重数始终小于或等于代数重数。

5. 特征值的分类

- **单特征值 (Simple Eigenvalue)**：代数重数为 1 的特征值。
- **重特征值 (Multiple Eigenvalue)**：代数重数大于 1 的特征值。
- **半单特征值 (Semi-simple Eigenvalue)**：代数重数 **等于** 几何重数的特征值。这意味着尽管它是重根，但能提供足够数量的线性无关特征向量。

6. 矩阵的性质：非亏损 (Non-defective)

- **亏损矩阵 (Defective Matrix)**：如果存在某个特征值，其几何重数小于代数重数（特征向量不够用），则称该矩阵为亏损矩阵。
- **非亏损矩阵 (Non-defective Matrix)**：
 - 所有特征值都是**半单**的（代数重数 = 几何重数）。
 - 该矩阵拥有 n 个线性无关的特征向量。
 - **结论**：非亏损矩阵一定可以进行**对角化**。

7. 相似变换： $B = XAX^{-1}$ ，且 X 非奇异。

对于任意多项式 $P(x) = \sum_{j=0}^n a_j x^j$ ，其伴随矩阵的特征多项式为 P 本身。

定理 6.1.1 (Jordan 分解定理)

设 $A \in \mathbb{C}^{n \times n}$ 有 r 个互不相同的特征值 $\lambda_1, \dots, \lambda_r$ ，其代数重数分别为 $n(\lambda_1), \dots, n(\lambda_r)$ ，则必存在一个非奇异矩阵 $P \in \mathbb{C}^{n \times n}$ ，使得

$$P^{-1}AP = \begin{bmatrix} J(\lambda_1) & & & \\ & J(\lambda_2) & & \\ & & \ddots & \\ & & & J(\lambda_r) \end{bmatrix} \tag{44}$$

其中 k_i 为几何重数。

$$J(\lambda_i) = \text{diag}(J_1(\lambda_i), \dots, J_{k_i}(\lambda_i)) \in \mathbb{C}^{n(\lambda_i) \times n(\lambda_i)}, \quad i = 1, \dots, r, \tag{45}$$

$$J_j(\lambda_i) = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix} \in \mathbb{C}^{n_j(\lambda_i) \times n_j(\lambda_i)}, \quad j = 1, \dots, k_i, \tag{46}$$

$$n_1(\lambda_i) + \dots + n_{k_i}(\lambda_i) = n(\lambda_i), \quad i = 1, \dots, r; \tag{47}$$

并且除了 $J_j(\lambda_i)$ 的排列次序可以改变外， J 是唯一确定的。

上述定理中的矩阵 J 称做 A 的 *Jordan 标准形*，其中每个子矩阵 $J_j(\lambda_i)$ 称做 *Jordan 块*。

定理 6.1.2 (*Schur* 分解定理)

设 $A \in \mathbb{C}^{n \times n}$, 则存在酉矩阵 $U \in \mathbb{C}^{n \times n}$, 使得

$$U^*AU = T, \tag{48}$$

其中 T 是上三角阵; 而且适当选取 U , 可使 T 的对角元按任意指定的顺序排列。

设 $U \in \mathbb{C}^{n \times n}$ 是一个复矩阵, 如果它满足以下条件:

$$U^*U = UU^* = I \tag{49}$$

则称 U 为酉矩阵。

其中:

- U^* 表示 U 的共轭转置 (Conjugate Transpose) , 即 $U^* = (\bar{U})^T$ 。
- I 是单位矩阵。

定理 6.1.3 (*Gerschgorin* 圆盘定理)

设 $A = [a_{ij}] \in \mathbb{C}^{n \times n}$, 令

$$G_i(A) = \left\{ z \in \mathbb{C} : |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}, \quad i = 1, \dots, n, \tag{50}$$

则有

$$\lambda(A) \subset G_1(A) \cup G_2(A) \cup \dots \cup G_n(A). \tag{51}$$

$\lambda(A)$ 代表矩阵 A 的特征值集合 (也称为矩阵的谱, 常用符号还有 $\sigma(A)$) 。

幂法的收敛性

设 $A \in \mathbb{C}^{n \times n}$ 是一个可对角化的矩阵, 其特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 对应的线性无关的特征向量为 $x_1, x_2, \dots, x_n$ 。

若满足以下条件:

1. 主特征值唯一性: 其特征值的模满足严格不等式: $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$
2. 非正交初始条件: 初始向量 $u_0 \in \mathbb{C}^n$ 在主特征向量 x_1 方向上的分量不为零。即若将 u_0 表示为特征向量的线性组合: $u_0 = \sum_{i=1}^n \alpha_i x_i$ 则要求系数 $\alpha_1 \neq 0$ 。

则有如下结论: 序列 $\{\frac{A^k u_0}{\lambda_1^k}\}$ 当 k 趋于无穷大时收敛于主特征向量的加权形式:

$$\lim_{k \rightarrow \infty} \frac{A^k u_0}{\lambda_1^k} = \alpha_1 x_1 \tag{52}$$

QR方法

QR方法的基础是将一个矩阵 A 分解为两个特定性质矩阵的乘积:

- Q : 正交矩阵 (Orthogonal Matrix) , 满足 $Q^T Q = I$ 。
- R : 上三角矩阵 (Upper Triangular Matrix) 。

定理 6.4.2 (实 Schur 分解)

设 $A \in \mathbf{R}^{n \times n}$, 则存在正交矩阵 $Q \in \mathbf{R}^{n \times n}$, 使得

$$Q^T A Q = \begin{bmatrix} R_{11} & R_{12} & \cdots & R_{1m} \\ & R_{22} & \cdots & R_{2m} \\ & & \ddots & \vdots \\ & & & R_{mm} \end{bmatrix} \quad (53)$$

其中 R_{ii} 或者是一个实数, 或者是一个具有一对复共轭特征值的 2 阶方阵。

第七章

定理 7.1.1 (谱分解定理)

若 $A \in \mathbf{R}^{n \times n}$ 是对称的, 则存在正交矩阵 $Q \in \mathbf{R}^{n \times n}$, 使得

$$Q^T A Q = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n). \quad (54)$$

定理 7.1.2 (极小极大定理)

设 $A \in \mathbf{R}^{n \times n}$ 是对称矩阵, 并假定 A 的特征值为 $\lambda_1 \geq \dots \geq \lambda_n$, 则有

$$\begin{aligned} \lambda_i &= \max_{\mathcal{X} \in \mathcal{G}_i^n} \min_{0 \neq u \in \mathcal{X}} \frac{u^T A u}{u^T u} \\ &= \min_{\mathcal{X} \in \mathcal{G}_{n-i+1}^n} \max_{0 \neq u \in \mathcal{X}} \frac{u^T A u}{u^T u}, \end{aligned} \quad (55)$$

其中 $\mathcal{G}_k^n$ 表示 $\mathbf{R}^n$ 中所有 k 维子空间的全体。

定理 7.1.3 (Weyl 定理)

设 n 阶对称矩阵 A 和 B 的特征值分别为

$$\lambda_1 \geq \dots \geq \lambda_n \quad \text{和} \quad \mu_1 \geq \dots \geq \mu_n, \quad (56)$$

则有

$$|\lambda_i - \mu_i| \leq \|A - B\|_2, \quad i = 1, \dots, n. \quad (57)$$

定理 7.1.5 (SVD 分解定理)

设 $A \in \mathbf{R}^{m \times n}$, 则存在正交矩阵 $U \in \mathbf{R}^{m \times m}$ 和 $V \in \mathbf{R}^{n \times n}$, 使得

$$U^T A V = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix} \begin{matrix} r \\ m-r \end{matrix}, \quad (58)$$

$$\begin{matrix} r & n-r \end{matrix} \quad (59)$$

其中 $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$, $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 。