

第二章第一节：范数

定义2.1.1 (向量范数, p41)

从 $\mathbb{R}^n$ 到 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 被称作 $\mathbb{R}^n$ 上的向量范数, 如果它满足

(1) 正定性: $\forall x \in \mathbb{R}^n, \|x\| \geq 0; \|x\| = 0 \iff x = 0$ 。

(2) 齐次性: $\forall x \in \mathbb{R}^n, \alpha \in \mathbb{R}, \|\alpha x\| = |\alpha| \|x\|$ 。

(3) 三角不等式: $\forall x, y \in \mathbb{R}^n, \|x + y\| \leq \|x\| + \|y\|$ 。

正定、齐次

三角不等式

$\|\cdot\|_1, \|\cdot\|_2, \|\cdot\|_\infty$, (p42)

定义2.1.2 (矩阵范数, p43)

从 $\mathbb{R}^{n \times n}$ 到 $\mathbb{R}$ 的非负函数 $\|\cdot\|$ 被称作 $\mathbb{R}^{n \times n}$ 上的向量范数, 如果它满足

(1) 正定性: $\forall A \in \mathbb{R}^{n \times n}, \|A\| \geq 0; \|A\| = 0 \iff A = 0$ 。(2) 齐次性: $\forall A \in \mathbb{R}^{n \times n}, \alpha \in \mathbb{R}, \|\alpha A\| = |\alpha| \|A\|$ 。(3) 三角不等式: $\forall A, B \in \mathbb{R}^{n \times n}, \|A + B\| \leq \|A\| + \|B\|$ 。(4) 相容性: $\forall A, B \in \mathbb{R}^{n \times n}, \|AB\| \leq \|A\| \|B\|$ 。

+ 相容

定理2.1.3 (从向量范数诱导出的矩阵范数, p44)

$\|\cdot\|_1$, 列和

定理2.1.4 (矩阵范数例子, $\|\cdot\|_1, \|\cdot\|_2, \|\cdot\|_\infty$, p46)

$\|\cdot\|_2$ 行和

定义2.1.4 (A 的谱半径, $\rho(A)$, p48)

$$\rho(A) = \max\{|\lambda| : \lambda \in \lambda(A)\},$$

这里 $\lambda(A)$ 代表 A 的特征值的全体。

定理2.1.6 (谱半径与矩阵范数关系, p49)

$$\forall \|\cdot\| \quad \rho(A) \leq \|A\|$$

定理2.1.7 (A^k 收敛的充分必要条件, p50)

$$\exists \|\cdot\| \quad \|A\| \leq \rho(A) + \varepsilon$$

$$\lim_{k \rightarrow \infty} A^k = 0 \iff \rho(A) < 1.$$

定理2.1.8 (A 的Neumann series, p51)

(1) $\sum_{k=0}^{\infty} A^k$ 收敛 $\iff \rho(A) < 1$ 。

(2) 当 $\sum_{k=0}^{\infty} A^k$ 收敛时, 有

$$\sum_{k=0}^{\infty} A^k = (I - A)^{-1}.$$

且存在范数 $\|\cdot\|$ 使得对于任意自然数 m , 有

$$\|(I - A)^{-1} - \sum_{k=0}^m A^k\| \leq \frac{\|A\|^{m+1}}{1 - \|A\|}.$$

第二章第二节：敏度分析

定理2.2.1 (p53), 定义2.2.1 (p54), 定理2.2.2 (p55)

第三章第一节：最小二乘问题

定义3.1.1 (最小二乘问题, LS问题, p77) 给定 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, 确定 $x \in \mathbb{R}^n$ 使得

$$\|b - Ax\|_2 = \|r(x)\|_2 = \min_{y \in \mathbb{R}^n} \|r(y)\|_2 = \min_{y \in \mathbb{R}^n} \|Ay - b\|_2.$$

r 被称为残向量。本章中, 限定 $\text{rank}(A) = n < m$.

$A \in \mathbb{R}^{m \times n}$, A 的值域为 $\mathcal{R}(A) = \{y \in \mathbb{R}^m : y = Ax, x \in \mathbb{R}^n\}$.

A 的零空间定义为 $\mathcal{N}(A) = \{x \in \mathbb{R}^n : Ax = 0\}$, 其维数为 $\text{null}(A)$.

$\mathcal{S} \subset \mathbb{R}^n$ 的正交补为 $\mathcal{S}^\perp = \{y \in \mathbb{R}^n : y^T x = 0, \forall x \in \mathcal{S}\}$.

$\mathcal{X}_{LS} = \{x \in \mathbb{R}^n : x \text{ 是最小二乘问题的解}\}$. $\mathcal{X}_{LS}$ 中 2 范数最小的解写为 x_{LS} , 并称之为最小 2 范数解。

定理3.1.1, 定理3.1.2, 推论3.1.1 (p78-79):
讨论了 $Ax = b$ 的解的存在唯一性, 和不唯一情形下解的集合表达式。

定理3.1.3 (p80):
线性最小二乘问题存在性, 和唯一性的充要条件。

定理3.1.4 (p80):
最小二乘问题的正则化方程。

$$\vec{x} \in \mathcal{X}_{LS} \Leftrightarrow A^T A \vec{x} = A^T \vec{b}$$

对于正则化方程 $A^T Ax = A^T b$ 和最小二乘解的关系，还可从变分法推出。定理3.1.4证明如下：

若 x 为最小二乘解，则 $x = \min_{y \in \mathbb{R}^n} \|Ay - b\|_2^2$ 。

对于 $\forall y \in \mathbb{R}^n$ ，我们可以定义 $f(a) = \|A(x + ay) - b\|_2^2$ ，则有 $f(a)$ 在 0 点取到最小值。若 $f(a)$ 在 $a = 0$ 处可导，其必为零。我们计算 $\epsilon^{-1}[f(\epsilon) - f(0)]$ 如下

$$\begin{aligned}\epsilon^{-1}[f(\epsilon) - f(0)] &= \epsilon^{-1} \left(\|A(x + \epsilon y) - b\|_2^2 - \|Ax - b\|_2^2 \right) \\ &= \epsilon^{-1} \left(\|A(x + \epsilon y)\|_2^2 + \|b\|_2^2 - 2\langle A(x + \epsilon y), b \rangle - \|Ax\|_2^2 - \|b\|_2^2 + 2\langle Ax, b \rangle \right) \\ &= \epsilon^{-1} \left(\|Ax\|_2^2 + \epsilon^2 \|Ay\|_2^2 + 2\epsilon \langle Ax, Ay \rangle - 2\epsilon \langle Ay, b \rangle - \|Ax\|_2^2 \right) \\ &= \epsilon \|Ay\|_2^2 + 2\langle Ax - b, Ay \rangle\end{aligned}$$

令 $\epsilon \rightarrow 0$ ，可以发现极限存在且为 $2\langle Ax - b, Ay \rangle$ 。因此我们有

$$f'(0) = \lim_{\epsilon \rightarrow 0} \epsilon^{-1}[f(\epsilon) - f(0)] = 2\langle Ax - b, Ay \rangle = 0.$$

我们已经证明对于任意 $y \in \mathbb{R}^n$ ， $\langle A^T(Ax - b), y \rangle = 0$ 。这意味着 $A^T Ax = A^T b$ 。

若正则化方程成立，即 x 满足 $A^T Ax = A^T b$ ，对于 $\forall y \in \mathbb{R}^n$ ，我们有

$$\begin{aligned}\|A(x + y) - b\|_2^2 &= \|Ay\|_2^2 - 2\langle Ax - b, Ay \rangle + \|Ax - b\|_2^2 \\ &= \|Ay\|_2^2 - 2\langle A^T(Ax - b), y \rangle + \|Ax - b\|_2^2 \\ &= \|Ay\|_2^2 + \|Ax - b\|_2^2 \\ &\geq \|Ax - b\|_2^2.\end{aligned}$$

由 y 的任意性，我们有 x 为 $Ax = b$ 的最小二乘解。

若 A 列线性无关, 则最小二乘解可写为 $x = (A^T A)^{-1} A^T b$ 。定义 $A^\dagger = (A^T A)^{-1} A^T$, 其为Moore-Penrose广义逆 (p82)。

定理3.1.5, 定理3.1.6 (p82-83):
 敏度分析和最小二乘问题条件数。条件数定义为 $\kappa_2(A) = \|A\|_2 \|A^\dagger\|_2$ 。

第三章第二节: Householder变换和Givens变换

定义3.2.1 (p84):
 对于 $w \in \mathbb{R}^n$ 且满足 $\|w\|_2 = 1$, 定义Householder变换 $H \in \mathbb{R}^{n \times n}$ 如下:

$$H = I - 2ww^T.$$

定理3.2.1 (p84):
 Householder变换性质, 对称性, 正交性, 对合性, 反射性。

定理3.2.2和之后内容 (p86-88):
 若要将向量 x 的第2到 n 个元素全变为零, 选取

$$H = I - \beta vv^T, \quad v = x \pm \|x\|_2 e_1, \quad \beta = 2/(v^T v).$$

考虑更一般的情形, 若要将向量 x 的第 $k+1$ 到 j 个元素变为零, 令

$$H = I - \beta vv^T, \quad v = (0, \dots, 0, x_k - \alpha, x_{k+1}, \dots, x_j, 0, \dots, 0), \quad \alpha^2 = \sum_{i=k}^j x_i^2, \quad \beta = 2/(v^T v).$$

Givens变换, 也被称为平面旋转变换, 即在 (i, k) 平面内将 x 顺时针旋转 θ 度。

$$G(i, k, \theta) = I + s(e_i e_k^T - e_k e_i^T) + (c - 1)(e_i e_i^T + e_k e_k^T),$$

$$c = \cos \theta = x_i(x_i^2 + x_k^2)^{-1/2}, \quad s = \sin \theta = x_k(x_i^2 + x_k^2)^{-1/2},$$

则有 $y = G(i, k, \theta)x$, $y_i = (x_i^2 + x_k^2)^{1/2}$, $y_k = 0$ 。

第三章第三节: QR分解定理

定理3.3.1 (QR分解, p91): 设 $A \in \mathbb{R}^{m \times n} (m \geq n)$, 则 A 的 QR 分解如下

$$A = Q \begin{bmatrix} R \\ 0 \end{bmatrix},$$

其中 $Q \in \mathbb{R}^{m \times m}$ 是正交矩阵, $R \in \mathbb{R}^{n \times n}$ 是具有非负对角元的上三角阵; 而且当 $m = n$ 且 A 非奇异时, 上述分解唯一。

正交变换法的实现, 理论部分 (p92), 算法部分 (p95)。

$$A = D - L - U$$

第四章：古典迭代法

$$\begin{aligned} Ax &= b \\ \implies \text{令 } A &= A_1 + A_2, \quad A_1 x = -A_2 x + b \\ \implies x &= -A_1^{-1} A_2 x + A_1^{-1} b \\ \implies x &= Mx + g. \end{aligned}$$

Jacobi迭代, Gauss-Seidel迭代, 定理4.2.1, 定理4.2.2, 定理4.2.3 (p105-107); 收敛性, 收敛速度。

定义4.2.1, 定义4.2.2 (p113): 对角占优, 可约不可约。

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

A 不是弱严格对角占优的。

定理4.2.8, 推论4.2.1 (p114-115): 对角占优, 可约, 可逆, 正定这些定义之间的关系。

定义 $R_k(M) = \frac{-\ln \|M^k\|}{k}$ 为 k 次迭代的平均收敛速度;

定义 $R_\infty(M) = \lim_{k \rightarrow \infty} R_k(M)$ 为渐近收敛速度。

定理4.3.1 (p117): 渐近收敛速度公式, $R_\infty(M) = -\ln \rho(M)$ 。

第五章第一节：最速下降法

$$Ax = b, \varphi(x) = x^T Ax - 2b^T x.$$

定理5.1.1 (p138) 方程组和二次泛函 φ 的关系。

最速下降法思路 and 实现：确定方向 p_k ，确定距离 α_k 。

$$p_k = r_k = b - Ax_k, \quad \alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}, \quad x_{k+1} = x_k + \alpha_k p_k.$$

迭代的过程为

$$x_k \implies (r_k, p_k, \alpha_k) \implies x_{k+1} \implies (r_{k+1}, p_{k+1}, \alpha_{k+1}) \implies \dots$$

算法5.1.1 (p141) 最速下降法的算法实现

定理5.1.2 (p141) 最速下降法的收敛性

第五章第二、三、四、五节：共轭梯度法

与最速下降法的区别在于下山方向和距离的选取。

$$r_{k+1} = r_k - \alpha_k A p_k, \quad \alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}, \quad \beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k},$$

$$x_{k+1} = x_k + \alpha_k p_k, \quad p_{k+1} = r_{k+1} + \beta_k p_k.$$

迭代的过程为

$$(x_k, p_{k-1}, \alpha_{k-1}) \implies (r_k = b - Ax_k, \beta_{k-1}) \implies (p_k, \alpha_k, x_{k+1}) \implies \dots$$

关于共轭梯度法系数 α_k, β_k 化简的证明

已知信息: $x_k = x_{k-1} + \alpha_{k-1}p_{k-1}$; $\alpha_k = r_k^T p_k / (p_k^T A p_k)$ (P140, 5.1.3);
 $p_k = r_k + \beta_{k-1}p_{k-1}$; $\beta_k = -(r_{k+1}^T A p_k) / (p_k^T A p_k)$.

从 β_k 信息出发, 我们有

$$r_k^T A p_{k-1} + \beta_{k-1} p_{k-1}^T A p_{k-1} = 0 \implies (r_k^T + \beta_{k-1} p_{k-1}^T) A p_{k-1} = 0 \implies p_k^T A p_{k-1} = 0.$$

从 α_k 信息出发, 我们有

$$\begin{aligned} r_k^T p_{k-1} &= (b - A x_k)^T p_{k-1} = [b - A(x_{k-1} + \alpha_{k-1} p_{k-1})]^T p_{k-1} = (r_{k-1} - \alpha_{k-1} A p_{k-1})^T p_{k-1} \\ &= r_{k-1}^T p_{k-1} - \alpha_{k-1} p_{k-1}^T A p_{k-1} = 0. \end{aligned}$$

由 $r_k^T p_{k-1} = 0$, 我们有

$$\begin{aligned} r_k^T r_{k+1} &= r_k^T (b - A x_{k+1}) = r_k^T [b - A(x_k + \alpha_k p_k)] = r_k^T (r_k - \alpha_k A p_k) \\ &= r_k^T (p_k - \beta_{k-1} p_{k-1} - \alpha_k A p_k) = r_k^T p_k - \alpha_k r_k^T A p_k. \end{aligned}$$

考虑到 $r_k = p_k - \beta_{k-1} p_{k-1}$ 和之前证明过的 $p_k^T A p_{k-1} = 0$ 还有 α_k 定义, 我们有
 $r_k^T p_k - \alpha_k r_k^T A p_k = r_k^T p_k - \alpha_k p_k^T A p_k + \alpha_k \beta_{k-1} p_{k-1}^T A p_k = 0$.
 因此, $r_k^T r_{k+1} = 0$.

对于 α_k , 从 $p_k = r_k + \beta_{k-1} p_{k-1}$, $r_k^T p_{k-1} = 0$ 出发我们有

$$\begin{aligned} r_k^T p_k - r_k^T r_k &= r_k^T \beta_{k-1} p_{k-1} = 0, \\ \text{所以 } \alpha_k &= r_k^T p_k / (p_k^T A p_k) = r_k^T r_k / (p_k^T A p_k). \end{aligned}$$

对于 β_k , 从 $x_{k+1} = x_k + \alpha_k p_k$ 出发, 我们有

$$r_{k+1} = b - A x_{k+1} = b - A(x_k + \alpha_k p_k) = r_k - \alpha_k A p_k \implies A p_k = \alpha_k^{-1} (r_k - r_{k+1}).$$

考虑到 $r_k^T r_{k+1} = 0$, 我们有

$$r_{k+1}^T A p_k = \alpha_k^{-1} r_{k+1}^T (r_k - r_{k+1}) = -\alpha_k^{-1} r_{k+1}^T r_{k+1}.$$

考虑到 $p_k = r_k + \beta_{k-1} p_{k-1}$, $r_k^T p_{k-1} = 0$, $r_k^T r_{k+1} = 0$, 我们有

$$p_k^T A p_k = \alpha_k^{-1} p_k^T (r_k - r_{k+1}) = \alpha_k^{-1} p_k^T r_k = \alpha_k^{-1} (r_k + \beta_{k-1} p_{k-1})^T r_k = \alpha_k^{-1} r_k^T r_k.$$

$$\text{所以 } \beta_k = -(r_{k+1}^T A p_k) / (p_k^T A p_k) = r_{k+1}^T r_{k+1} / (r_k^T r_k).$$

综上, $\alpha_k = r_k^T r_k / (p_k^T A p_k)$, $\beta_k = r_{k+1}^T r_{k+1} / (r_k^T r_k)$.

定理5.2.1 证明（详细版）

对于结论(1) – (4)，易知对于 $k = 1$ 时都成立。使用归纳法，假设 $k \leq n$ 时结论(1) – (4)成立，我们需要证明对于 $k = n + 1$ 时结论(1) – (4)成立。

对于（4）前半部分，由 $r_{n+1} = p_{n+1} - \beta_n p_n$ ，有
 $\text{Span}\{r_0, \dots, r_{n+1}\} = \text{Span}\{p_0, \dots, p_n, p_{n+1} - \beta_n p_n\} = \text{Span}\{p_0, \dots, p_n, p_{n+1}\}.$

对于（1），由归纳假设，我们有
 $p_i^T r_{n+1} = p_i^T (r_n - \alpha_n A p_n) = p_i^T r_n - \alpha_n p_i^T A p_n = 0, i = 0, \dots, n-1.$ 对于 $p_n^T r_{n+1}$ ，我们有 $p_n^T r_{n+1} = p_n^T (r_n - \alpha_n A p_n)$ 。由 α_n 定义，得知 $p_n^T r_{n+1} = 0$ 。因此，结论（1）成立。

对于（2），由结论（1）可得 r_{n+1} 与 $\text{Span}\{p_0, \dots, p_n\}$ 正交。再由结论（4）前半部分，有 r_{n+1} 与 $\text{Span}\{r_0, \dots, r_n\}$ 正交。因此，结论（2）成立。

对于（3），首先我们有 $p_{n+1} = r_{n+1} + \beta_n p_n, r_{i+1} = r_i - \alpha_i A p_i$ ，然后
 $p_i^T A p_{n+1} = p_i^T A r_{n+1} + \beta_n p_i^T A p_n = \alpha_i^{-1} (r_i - r_{i+1})^T r_{n+1} + \beta_n p_i^T A p_n.$
 由结论（2）和归纳假设，我们有 $p_i^T A p_{n+1} = 0$ 对于 $i = 0, \dots, n-1$ 。
 对于 $p_n^T A p_{n+1}$ ，我们有 $p_n^T A p_{n+1} = p_{n+1}^T A p_n = (r_{n+1} + \beta_n p_n)^T A p_n = 0$ 。之前等式用到了 β_n 定义。因此结论（3）成立。

对于（4）后半部分，首先结论（2）和结论（4）前半部分给出了 $\{r_0, \dots, r_{n+1}\}$ 和 $\{p_0, \dots, p_{n+1}\}$ 的线性无关性质。再由 $r_{n+1} = r_n - \alpha_n A p_n$ ，我们有
 $\text{Span}\{r_0, \dots, r_n, r_{n+1}\} = \text{Span}\{r_0, \dots, r_n, A p_n\} = \text{Span}\{p_0, \dots, p_n, A p_n\}$
 $= \text{Span}\{r_0, \dots, A^n r_0, A p_n\}.$
 因 $A p_n \in \text{Span}\{A p_0, \dots, A p_n\} = \text{Span}\{A r_0, \dots, A^{n+1} r_0\},$
 所以有 $\text{Span}\{r_0, \dots, r_n, r_{n+1}\} = \text{Span}\{r_0, \dots, A^n r_0, A p_n\} \subset \text{Span}\{r_0, \dots, A^{n+1} r_0\}.$
 对于 $A^{n+1} r_0$ ，我们有
 $A^{n+1} r_0 = A(A^n r_0) \in \text{Span}\{A p_0, \dots, A p_n\} = \text{Span}\{A r_0, \dots, A^n r_0, A p_n\}$
 $\subset \text{Span}\{r_0, \dots, A^n r_0, A p_n\}.$
 上述结果用到了 $\text{Span}\{A p_0, \dots, A p_{n-1}\} = \text{Span}\{A r_0, \dots, A^n r_0\}.$
 从而可得 $\text{Span}\{r_0, \dots, A^n r_0, A^{n+1} r_0\} \subset \text{Span}\{r_0, \dots, A^n r_0, A p_n\}.$
 因此， $\text{Span}\{r_0, \dots, r_{n+1}\} = \text{Span}\{r_0, \dots, A^n r_0, A^{n+1} r_0\}.$ 结论（4）成立。

算法5.2.1 (p146) 共轭梯度法的算法实现

定理5.2.1 (p146) 共轭梯度法的性质, Krylov子空间定义。

定理5.2.2 (p148) 共轭梯度法和Krylov子空间关系。

算法5.3.1 (p150) 实用共轭梯度法, 其本质就是限制迭代次数。

定理5.3.1, 定理5.3.2 (p150-151) 共轭梯度法收敛性, 迭代次数和误差估计。

预优共轭梯度法: 找寻对称正定 C , 使得 $C^{-1}Ac^{-1}$ 为仅有少数几个互不相同特征值或非常良态的等价方程组。

记 $M = C^2$, 关于 M 的特征和例子见p154-155。已知 M , 算法实现见算法5.4.1 (p153)。

Krylov子空间法: 正则化方法, 残量极小化方法, 残量正交化方法 (p157-158)。

第六章第一节：线性代数知识回顾

特征值，特征向量，特征多项式，谱集，重数，单特征值，重特征值，半单特征值，非亏损

相似变换： $B = XAX^{-1}$ ，且 X 非奇异。

对于任意多项式 $P(x) = \sum_{j=0}^n a_j x^j$ ，其伴随矩阵的特征多项式为 P 本身。如何证明？

定理6.1.1：（Jordan分解定理，p162）

定理6.1.2：（Schur分解定理，p163）

定理6.1.3：（Gerschgorin圆盘定理，p163）

特征值、特征向量条件数： $\|y\|_2, \|\Sigma^\perp\|_2$ 。其中 $y^T A = \lambda y^T$ ， y 为 A 的属于 λ 的左特征向量。

第二节：幂法

$A \in \mathbb{C}^{n \times n}$ 可对角化，且特征值满足 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ ，则 $\lim_{k \rightarrow \infty} A^k u_0 / \lambda_1^k = \alpha_1 x_1$ ， x_1 为关于 λ_1 的特征向量。

幂法算法：（6.2.6）；定理6.2.1（幂法收敛性）

第四节：QR方法

迭代算法： $A_{m-1} = Q_m R_m, A_m = R_m Q_m, m = 1, 2, \dots$ 。可以推导出 $A^m = \tilde{Q}_m \tilde{R}_m$ ，再考虑到幂法，可得 $A^m e_1 = \gamma_{11} q_1^{(m)}$ 。

收敛性定理：定理6.4.1

章节6.4.2：实数情形

实Schur标准形，见（6.4.10）。定理6.4.2（实Schur分解），上Hessenberg矩阵，上Hessenberg分解（p181）。

定理6.2.1证明补充:

之前的推导为若当标准形的基本应用, 补充部分从(6.2.8)开始, 即

$$\lim_{k \rightarrow \infty} \frac{1}{\lambda_1^k} A^k u_0 = X_1 y_1.$$

因为 u_0 在 λ_1 的特征子空间上投影不为零, 我们有 $X_1 y_1 \neq 0$ 。由以上结果, 我们可以得到

$$X_1 y_1 = \lim_{k \rightarrow \infty} \frac{1}{\lambda_1^k} A^k u_0 = \lim_{k \rightarrow \infty} \frac{A}{\lambda_1} \frac{A^k}{\lambda_1^k} u_0 = \frac{A}{\lambda_1} (X_1 y_1).$$

上述等式中需交换极限和矩阵乘法运算, 因我们考虑的矩阵是有限维的, 因此可以交换次序。这意味着 $X_1 y_1$ 为 A 关于 λ_1 的特征向量。接下来我们证明 u_k 的极限就是常数乘以 $X_1 y_1$ 。

关于幂法(6.2.6), 我们需要增加一个额外条件, 即当 Au_{k-1} 存在多个模最大分量时, 取指标最小的。否则未必能够得到 u_k 的收敛性。由幂法(6.2.6)得知

$$u_k = \frac{Au_{k-1}}{\mu_k} = \frac{A^k u_0}{\mu_k \cdots \mu_1} = \frac{A^k u_0}{\lambda_1^k} \frac{\lambda_1^k}{\mu_k \cdots \mu_1},$$

且 $\frac{\mu_k \cdots \mu_1}{\lambda_1^k}$ 为 $\frac{A^k u_0}{\lambda_1^k}$ 的模最大分量。由蓝字部分以及 $\frac{A^k u_0}{\lambda_1^k}$ 的收敛性可以得到 $\frac{\mu_k \cdots \mu_1}{\lambda_1^k}$ 的收敛性。记 $\zeta = \lim_{k \rightarrow \infty} \frac{\mu_k \cdots \mu_1}{\lambda_1^k}$, 我们有

$$\lim_{k \rightarrow \infty} u_k = X_1 y_1 / \zeta.$$

所以有 u_k 收敛到 A 关于 λ_1 的一个特征向量。再由

$$\zeta = \lim_{k \rightarrow \infty} \frac{\mu_{k+1}}{\lambda_1} \frac{\mu_k \cdots \mu_1}{\lambda_1^k} = \lim_{k \rightarrow \infty} \frac{\mu_{k+1}}{\lambda_1} \zeta$$

可得 $\lim_{k \rightarrow \infty} \mu_k = \lambda_1$ 。

第七章第一节：关于对称矩阵的性质

谱分解（对角化）：定理7.1.1，
极大极小定理（关于特征值）：定理7.1.2，
特征值特征向量敏感性：定理7.1.3，定理7.1.4。
SVD分解：定理7.1.5。

第二节：QR方法

三对角化 $\Rightarrow$ 隐式对称QR迭代 $\Rightarrow$ 隐式对称QR算法

第三节：Jacobi方法（和Givens变换有相似之处）

旋转曲面的选择和旋转角度的选取（7.3.2），（7.3.6），（7.3.7）。

第四节：二分法（针对实对称三对角阵，证明较难）

顺序主子式估计：定理7.4.1。
符号变化次数和特征值个数的估计：定理7.4.2，推论7.4.1。

第五节：分而治之法（分块，针对实对称三角阵）

如何分块：（7.5.3）
粘合：定理7.5.1，定理7.5.2。
过程简述：p231-232。

第六节：奇异值分解计算（非方阵，选讲内容）